

Module Quiz and Answer

1. What is the main difference between Linear Regression and Logistic Regression?

- a) Linear Regression uses trees, Logistic Regression uses lines
- b) Linear Regression predicts continuous values, Logistic Regression predicts categories
- c) Logistic Regression can only work with numbers
- d) Linear Regression is faster than Logistic Regression

Ans: b) Linear Regression predicts continuous values, Logistic Regression predicts categories

ব্যাখ্যা: Linear Regression একটি continuous value predict করে যেমন বাড়ির দাম।

কিন্তু Logistic Regression একটি category predict করে — যেমন survived/not survived।

2. In the Titanic dataset used in this module, what does the target column Survived contain?

- a) 0 and 1
- b) True and False
- c) "yes" and "no"
- d) 1 and 2

Ans: c) "yes" and "no"

ব্যাখ্যা: এই module-এর dataset-এ Survived column-এ "yes" এবং "no" string value আছে।

এটা standard 0/1 নয়, তাই পরে encoding দরকার হয়।

3. What does the "Accuracy" metric measure in a classification model, and in which scenario is it most likely to provide a misleading evaluation?

- a) It measures only the correct positive predictions; misleading when false negatives are high.
- b) It measures the overall proportion of correct predictions; misleading when the dataset is highly imbalanced.
- c) It measures the ratio of true positives to false positives; misleading when classes are equally distributed.
- d) It measures the model's ability to find all actual positives; misleading when false positives are costly.

Ans: b) It measures the overall proportion of correct predictions; misleading when the dataset is highly imbalanced.

ব্যাখ্যা: Accuracy হলো মোট প্রেডিকশনের মধ্যে মডেলটি কতগুলো সঠিক প্রেডিকশন (True Positives + True Negatives)

করেছে তার অনুপাত। এর সূত্র: $(TP + TN) / \text{Total Predictions}$ । তবে ডেটাসেট যদি imbalanced হয় (যেমন ১০০ জন রোগীর মধ্যে ৯৫ জন সুস্থ এবং ৫ জন অসুস্থ), তখন মডেলটি না বুঝেই সবাইকে "সুস্থ" প্রেডিক্ট করলেও ৯৫% Accuracy দেখাতে পারে। মডেলটি আসলে অসুস্থ রোগীদের শনাক্ত করতে ব্যর্থ হলেও Accuracy অনেক হাই দেখায়, যা অত্যন্ত misleading।

4. What does the stratify=y parameter do in train_test_split?

- a) It sorts the data before splitting
- b) It ensures both train and test sets have a similar ratio of survived vs not survived
- c) It removes duplicate rows
- d) It balances the number of rows in train and test

Ans: b) It ensures both train and test sets have a similar ratio of survived vs not survived

ব্যাখ্যা: stratify=y দিলে train এবং test উভয় set-এ target class-এর proportion

একই থাকে। যদি 40% passenger survive করে থাকে, তাহলে দুটোতেই প্রায় 40% survive থাকবে।

Learning: Stratified splitting prevents class imbalance between train and test sets.

5. In a classification model, what does the "Recall" metric primarily evaluate, and in which scenario is it most critical to maximize it?

- a) The proportion of correct positive predictions;
- b) The ability to find all actual positive cases; important when false negatives are highly dangerous.
- c) The overall correctness of the model; important for perfectly balanced datasets.
- d) Important for Regression Performance .

Ans: b) The ability to find all actual positive cases; important when false negatives are highly dangerous.

ব্যাখ্যা: Recall (বা Sensitivity) মূলত পরিমাপ করে যে, বাস্তবে যতগুলো "Positive" কেস ছিল, মডেল তার মধ্যে কতগুলোকে সঠিকভাবে শনাক্ত করতে পেরেছে। এর সূত্র হলো: $\text{True Positives} / (\text{True Positives} + \text{False Negatives})$ । যখন False Negative-এর ঝুঁকি অনেক বেশি থাকে (যেমন: রোগ নির্ণয় বা ব্যাংক ফ্রড ডিটেকশন, যেখানে একজন অসুস্থ মানুষকে ভুল করে সুস্থ বললে মারাত্মক ক্ষতি হতে পারে), তখন Recall-এর উপর সবচেয়ে বেশি জোর দেওয়া হয়।

6. What does the "Precision" metric primarily evaluate in a classification model?

- a) The proportion of actual negative cases that were correctly identified
- b) The overall percentage of correct predictions across all classes
- c) The proportion of positive predictions that were actually correct
- d) The harmonic mean of True Positives and False Negatives

Ans: c) The proportion of positive predictions that were actually correct

ব্যাখ্যা: Precision মূলত পরিমাপ করে মডেল যতগুলোকে "Positive" হিসেবে প্রেডিক্ট করেছে, তার মধ্যে আসলেই কতগুলো Positive ছিল। এর সূত্র হলো: $\text{True Positives} / (\text{True Positives} + \text{False Positives})$ । যখন False Positive কমানো আমাদের মূল লক্ষ্য হয় (যেমন: দরকারি ইমেইল যেন ভুল করে Spam ফোল্ডারে না যায়), তখন Precision-এর উপর বেশি জোর দেওয়া হয়।

7. Which encoder is used for the Pclass column, and why?

- a) OneHotEncoder, because Pclass has no order
- b) LabelEncoder, because it is the simplest

- c) OrdinalEncoder, because first class is better than third class
- d) StandardScaler, because Pclass is numerical

Ans: c) OrdinalEncoder, because first class is better than third class

ব্যাখ্যা: Pclass-এ একটি natural order আছে — third < second < first।

OrdinalEncoder এই order maintain করে encode করে।

Learning: Use OrdinalEncoder when categories have a meaningful order.

8. What does remainder='drop' mean in ColumnTransformer?

- a) It drops rows with missing values
- b) It removes columns not mentioned in the transformers list
- c) It deletes duplicate columns
- d) It drops the target column automatically

Ans: b) It removes columns not mentioned in the transformers list

ব্যাখ্যা: ColumnTransformer-এ শুধু নির্দিষ্ট column গুলোর জন্য pipeline define করা হয়।

remainder='drop' মানে বাকি সব column (Name, Ticket, PassengerId) automatically বাদ দেওয়া হবে।

Learning: remainder='drop' ensures only selected and transformed features reach the model.

9. What does class_weight='balanced' do in LogisticRegression?

- a) It makes the model train faster
- b) It gives more importance to the minority class during training
- c) It balances the number of rows in train and test
- d) It sets all feature weights to equal values

Ans: b) It gives more importance to the minority class during training

ব্যাখ্যা: যদি dataset-এ একটি class অনেক কম থাকে, তাহলে model সেই class ignore করতে পারে।

class_weight='balanced' দিলে model automatically minority class-কে বেশি গুরুত্ব দেয়।

Learning: Use class_weight='balanced' when your dataset has unequal class distribution.

10. What does the predict() method return in Logistic Regression?

- a) Probability scores between 0 and 1
- b) The predicted class label for each input
- c) The model accuracy score
- d) The loss value during training

Ans: b) The predicted class label for each input

ব্যাখ্যা: predict() method প্রতিটি input row-এর জন্য একটি class label return করে — যেমন "yes" অথবা "no"। এটি probability নয়, সরাসরি prediction। probability দেখতে চাইলে predict_proba() ব্যবহার করতে হয়।

Learning: predict() returns class labels, predict_proba() returns probability scores.